

“Predicción de la tasa de delitos por distrito en el Perú considerando índice de victimización, población y denuncias policiales.”

Autores: Guevara C., Saco S., Pasache J., Reaño C.

Resumen- Este trabajo se enfoca en la problemática de inseguridad ciudadana en el Perú, específicamente en una manera de abordarla de forma preventiva, que es el poder predecir la ocurrencia de criminalidad. En base a ello, se plantea un desarrollo y evaluación de tres modelos predictivos con el uso de machine learning, a fin de poder elegir el que más se adecúe al caso específico. Para ello, se hace uso de datos importantes como las denuncias, victimización y la población en el país.

1. Introducción

En el Perú, la inseguridad ciudadana es uno de los problemas sociales principales. Diariamente ocurren delitos como robo, hurto, extorsión; los cuales siguen incrementando en cantidad conforme pasan los años. El INEI (2024) informó que un 27.7% de la población del país sufrió de algún hecho delictivo durante el primer semestre de 2024. Además, según el informe de percepción de inseguridad ciudadana, elaborado por el INEI, en 2024 se incrementó esta percepción en porcentaje un 4,5% respecto al año anterior (de 82.6% a 88.1%), dándonos cifras de 89.9% y 88.5% para Lima Metropolitana y la Provincia Constitucional del Callao, respectivamente.

Tales sucesos ocasionan que tanto la calidad de vida como la sensación de seguridad que tienen los pobladores no sea buena, por lo que una gran cantidad de los mismos transitan por las calles con el miedo a vivir estas situaciones.

Ante este panorama, la predicción del crimen se vuelve fundamental al momento de abordar este problema, lo que ocasiona la búsqueda de la implementación de estrategias óptimas con las cuales poder predecir la ocurrencia de dichos delitos. Es por ello que, en este artículo, con el objetivo de desarrollar un algoritmo que resulte eficiente para predecir esta problemática se compararon 3 modelos de machine learning, para escoger la opción que brinde predicciones más aproximadas a la realidad, se tiene planeado analizar patrones recurrentes que nos ayuden a predecir la tasa de criminalidad de los próximos meses, dependiendo del distrito. Este análisis se realiza en base a conjuntos de datos de población, encuestas, denuncias, entre otros.

2. Trabajos relacionados

A continuación se presenta un resumen de artículos científicos relacionados al objetivo del artículo.

Título: Datos y Criminalidad: Machine Learning aplicado en modelos predictivos en seguridad.

Este estudio analiza el incremento de la criminalidad en Ecuador mediante un enfoque basado en datos abiertos y técnicas de Machine Learning. El trabajo busca evaluar si los datos públicos disponibles permiten construir modelos predictivos útiles para comprender patrones delictivos y apoyar la toma de decisiones en materia de seguridad. Los autores recopilaron y procesaron información del Consejo de la Judicatura y del INEC correspondiente a 2016-2023. Después de una limpieza y unificación de datos se aplicó el algoritmo Random Forest para predecir la incidencia delictiva.

Título: Prediciendo el crimen en ciudades intermedias: un modelo de “machine learning” en Bucaramanga, Colombia

Esta investigación analiza la criminalidad en Bucaramanga, Colombia, mediante la aplicación de técnicas de Machine Learning para predecir la ocurrencia del delito en ciudades intermedias. El trabajo utiliza un modelo de aprendizaje supervisado que integra información espacio-temporal con variables socioeconómicas y urbanas. Emplearon datos georreferenciados de denuncias delictivas registradas por la Policía Nacional entre 2018 y 2021. La metodología se basa en el procesamiento de señales para grafos y en la metodología de vectorización del análisis de texto con una vectorización de delitos a través del tiempo.



Título: La morfología de la criminalidad urbana en el Perú: un análisis de tendencias, niveles y factores de riesgo

El estudio analiza la morfología de la criminalidad urbana en el Perú a partir de la identificación de sus niveles, tendencias y factores de riesgo. Se emplearon datos de INEI - Estadísticas de Seguridad del 2023 y el Sistema Integrado de Estadística de la Criminalidad y Seguridad Ciudadana (DATACRIM, 2023). Todo el procesamiento se realizó en RStudio. Se aplicó una matriz de distancias euclidianas para evaluar la similitud entre territorios y se determinó la estructura óptima de agrupamiento mediante el método de la silueta, estableciendo dos clusters principales.

Título: Un enfoque espacio temporal para la predicción de delitos en la ciudad de Buenos Aires

El estudio desarrolla un modelo predictivo de criminalidad en la Ciudad Autónoma de Buenos Aires (CABA), integrando componentes espaciales y temporales para estimar la ocurrencias de delitos en esquinas específicas. Se hizo uso de registros mensuales de robos ocurridos entre 2017 y 2020. La metodología se estructura en dos enfoques, el primero en modelos de series de tiempo (ARIMA y Croston) aplicados al recuento histórico de delitos; el segundo, modelos de aprendizaje automático que incorporan variables espaciales y climáticas. Este segundo enfoque emplea el algoritmo Extreme Gradient Boosting (XGBoost), optimizando mediante búsqueda bayesiana de hiperparámetros y evaluado con validación cruzada k-fold y validación cruzada espacial basada en k-medias para mitigar correlaciones geográficas.

3. Metodología

Recolección de datos:

En la presente investigación, se desea realizar una predicción que muestre el nivel de inseguridad de la población en futuros periodos de tiempo. Esto se planea lograr mediante un modelo de machine learning utilizando como fuente de datos los resultados de la encuesta nacional de programas presupuestales (ENAPRES) realizada por el Instituto Nacional de Estadística e Informática (INEI). Esta encuesta comprende datos recopilados de los últimos 15 años. Esta base de datos cuenta con numerosos registros asociados a entrevistados, con información de crímenes reportados por los ciudadanos, así como, características particulares que podrían haber influido en el incidente.

Encuesta Nacional de Programas Presupuestales 2024						
DICCIONARIO DE VARIABLES						
CAPÍTULO 600 SEGURIDAD CIUDADANA (Para personas de 14 y más años de edad)						
Nro.	Nombre del Campo	Descripción	Valor	Tipo	Longitud	
1	AÑO	AÑO		A	4	
2	MES	MES DE LA ENCUESTA		A	2	
3	CONSUMIENDO	¿SE CONSUMIENDO?		A	1	
4	VIVIENDA	¿TIPO DE VIVIENDA?		A	6	
5	BOGAS	BOGAS MP		N	11	
6	POSTI	¿TIPO DE VIVIENDA?		N	11	
7	POSTI	¿TIPO DE VIVIENDA?		N	11	
8	RELEV	¿TIPO DE SELECCIÓN DE LA VIVIENDA?		A	4	
9	TRELV	¿TIPO DE SELECCIÓN DE LA VIVIENDA?		N	11	
10	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
11	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
12	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
13	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
14	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
15	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
16	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
17	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
18	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
19	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	
20	VIVEND	¿ES UNA VIVIENDA DE REEMPLAZO?		N	11	

Figura 1: Dicionario de datos del dataset ENAPRES

Para complementar el análisis incorporaremos como segundo conjunto de datos la información registrada en el DataSet Denuncias Policiales - Enero 2018 a Agosto 2025 que reúne data detallada sobre las denuncias policiales registrada en el Sistema Informático de Denuncias Policiales (SIDPOL) a nivel nacional, organizada por año, mes departamento y tipo de hecho reportado.

Por último se utilizará el DataSet: "IDH 2017-2024 A NIVEL DISTRITAL" proporcionado por el Programa de Naciones Unidas para el Desarrollo (PNUD), este dataset cuenta con variables socioeconómicas que representan la situación de los pobladores (Población, Educación, Ingreso per cápita, etc.) del país por ubigeo y periodo de tiempo.

En la Figura 2 se presenta un gráfico de barras agrupadas que muestra la distribución y evolución del número de denuncias registradas en los departamentos del Perú para el periodo 2022-2024. Estos datos de incidencia delictiva constituyen una variable fundamental para el entrenamiento y validación de nuestro algoritmo de pronóstico de criminalidad.

La tendencia más prominente es la extrema concentración de denuncias en Lima Metropolitana, donde se superan los 350,000 reportes anuales. Este volumen no solo es un reflejo de su alta población sino que también lo posiciona como el principal foco de desafío para la seguridad ciudadana.




Figura 2: Conteo de denuncias en los departamentos del Perú (2022-2024)

Para la investigación utilizaremos información dentro de un intervalo de tiempo que comprende los últimos 3 años (2022 - 2024). El análisis se realizará de manera mensual por lo que se dispondrá de 36 meses de datos.

En la figura 3 tenemos una vista consolidada de las variables determinantes del delito, acá podemos ver una correlación entre el ingreso per cápita y los años de escolaridad, sin embargo para el algoritmo hay 2 zonas de principal interés: El cuadrante inferior izquierdo que vendría a ser la zona de alta vulnerabilidad que representan según la teoría un riesgo latente de criminalidad y la zona de alta densidad que sería el cuadrante superior derecho donde a pesar de tener un indicador azul (alto desarrollo) el problema recae en la saturación demográfica y desigualdad urbana.




Figura 3: Matriz de riesgo socioeconómico promedio (2022 - 2024)

Enfoque propuesto:

La metodología a seguir consiste en un preprocesamiento de los datos con el objetivo de transformarlos en un conjunto estructurado que permita un correcto entrenamiento de los modelos que se usarán.

Debido al planteamiento del problema se buscará comparar tres algoritmos: Regresión lineal, XGBOOST (Extreme Gradient Boost) y KNN (k-nearest neighbors). Analizaremos los resultados que presenten estos 3 modelos y escogeremos el que brinda predicciones más aproximadas a la realidad.

El enfoque que se va a seguir consiste en entrenar los modelos para que predigan la tasa de criminalidad según distrito para próximos periodos de tiempo.

Para evitar sesgos se considerará:

$$T_{i,t} = 100000 \times \frac{Y_{i,t}}{P_{i,t}}$$

Donde:

- $Y_{i,t}$: Denuncias SIDPOL en un distrito y mes específicos.

- $P_{i,t}$: Población en un distrito en un distrito y mes específicos
- $T_{i,t}$: Tasa de crimen en un distrito y mes específicos.

Se aplicará la transformación logarítmica para evitar sesgos, estabilizar la varianzas:

$$T_{i,t}^{(\log)} = \log(1 + T_{i,t})$$

Los modelos a utilizar tendrán las siguientes características:

Regresión lineal:

$$T_{i,t}^{(\log)} = \beta_0 + \beta_1 \log(1 + \text{pob}_{i,t}) + \beta_2 \log(1 + \text{per_cap}_{i,t}) + \beta_3 \text{esp_vida}_{i,t} + \beta_4 \text{anios_edu}_{i,t} + \beta_5 \text{inseg_total}_{i,t} + \beta_6 \text{inseg_dia}_{i,t} + \beta_7 \text{conf_pnp_baja}_{i,t} + \beta_8 \text{evita_salir_noche_bin}_{i,t} + \beta_9 \text{MES_sin}_t + \beta_{10} \text{MES_cost}$$

Donde:

- $T_{i,t}^{(\log)}$: $\log(1 + \text{tasa de criminalidad})$ en distrito i , mes t (Variable objetivo)
- $\text{pob}_{i,t}$: Población por distrito en un mes.
- $\text{per_cap}_{i,t}$: Ingreso per cápita por distrito en un mes.
- $\text{esp_vida}_{i,t}$: Esperanza de vida por distrito en un mes.
- anios_edu_i : Años promedio de educación por distrito en un mes.
- $\text{inseg_total}_{i,t}$: Percepción de inseguridad general por distrito en un mes.
- $\text{inseg_dia}_{i,t}$: Percepción de inseguridad durante el día por distrito en un mes.
- $\text{conf_pnp_baja}_{i,t}$: Confianza en la Policía Nacional por distrito en un mes.
- $\text{evita_salir_noche_bin}_{i,t}$: Indicador si la población evitar salir de noche por distrito en un mes.
- $\text{MES_sin}_t, \text{MES_cost}_t$: Codificación cíclica del mes (Estacionalidad mensual).
- $\beta_0, \beta_1, \dots, \beta_{10}$ (Coeficientes): Coeficientes a estimar
- $\epsilon_{i,t}$ (Término de Error): Representa la variabilidad en la tasa de criminalidad que no es explicada por las variables predictoras incluidas en el modelo.

XGBOOST (Extreme Gradient Boost):

Entrada (vector $X_{i,t}$):

$$X_{i,t} = [\log(1 + \text{pob}_{i,t}), \log(1 + \text{per_cap}_{i,t}), \text{esp_vida}_{i,t}, \text{anios_edu}_{i,t}, \text{inseg_total}_{i,t}, \text{conf_pnp_baja}_{i,t}, \text{evita_salir_noche_bin}_{i,t}, \text{MES_sin}_t, \text{MES_cost}_t]$$



El modelo XGBoost aproxima la función.

$$T_{i,t}^{(log)} \approx f(x_{i,t}),$$

mediante una serie de árboles de decisión entrenados de manera secuencial.

KNN (k-nearest neighbors):

Este es un algoritmo no paramétrico. Debido a la sensibilidad del mismo, se ha escalado todas las variables al rango de 0 a 1. Para cada par distrito-mes, se compara con el resto de observaciones de entrenamiento, seleccionando los k vecino más cercanos y la predicción de $T_{i,t}^{(log)}$, se obtiene como promedio ponderado.

$$T^{^i,t(log)} = \frac{\sum_{j \in N_k(i,t)} w_{ij} T_j(log)}{\sum_{j \in N_k(i,t)} w_{ij}}$$

donde $N_k(i,t)$ es el conjunto de los k vecinos más cercanos y w_{ij} son pesos decrecientes.

En los tres experimentos las predicciones finales se devuelven a la escala original con $\exp(T_{i,t}^{(log)}) - 1$

Preprocesamiento de datos:

Se buscó construir un único dataset a partir de los demás que contará con las variables con mayor relevancia y que cuente con los datos estructurados en base a tiempo y espacio.

Para lograr esto se siguieron las siguientes etapas para la adecuación de los datos:

Limpieza y estandarización de los DataSets ENAPRES (2022-2024):

Los datos proporcionados por el *Instituto Nacional de Estadística e Informática (INEI)*, en relación a las encuestas de seguridad ciudadana, vienen separados en archivos por año (2010-2024). Para la presente investigación se decidió usar los datos correspondientes a los tres últimos años (2022-2024). Los conjuntos de datos están estructurados de la siguiente manera:

Cada dataset contiene:

- **ANIO:** Año de la encuesta.
- **MES:** Mes en que se realizó la encuesta (1-12).
- **CCDD, CCPP, CCDI:** Código departamental, provincial y distrital.
- **FACTOR o FACTOR_CAP600:** Es un peso muestral que indica a cuántas personas reales representa un encuestado.

- Más de 600 columnas con respuestas a preguntas del cuestionario.

Problema encontrado:

Las columnas no son consistentes entre años, estas cuentan con problemas como intercambio de posiciones, cambio de nombre o preguntas presentes en un año pero no en otro.

Solución aplicada:

Considerando esto se decidió reducir todos los dataset a las variables más importantes que guarden coherencia entre conjuntos de datos. Para esto se usó como referencia el diccionario de variables de cada año (2022-2024), ubicando dichas columnas y eliminando aquellas que con información irrelevante o que no existan por igual en los diferentes datasets. Se igualó el nombre de las columnas que cuenten con resultados a las mismas preguntas. De esta manera estandarizamos las tablas que serán usadas. El subconjunto de variables seleccionadas fue:

- Percepción de inseguridad general (perc_inseg_total).
- Percepción de inseguridad durante el día (perc_inseg_dia)
- Confianza en la Policía Nacional (conf_pnp)
- Conducta preventiva de evitar salir de noche (evita_salir_noche)

Las columnas que fueron seleccionadas fueron renombradas, de forma que los tres datasets quedaron estructuralmente idénticos.

Finalmente los conjuntos de datos se apilaron verticalmente.

Comparación por UBIGEO-ANIO-MES mediante ponderación :

Como se observa que para un mismo ubigeo, dentro del mismo mes y año hay múltiples entradas (encuestados). Con el objetivo de realizar un análisis predictivo, la unidad experimental será **Ubigeo x Mes x Año**. Por esto se comprimieron todas las entradas (Respuestas) usando el FACTOR muestral:

$$y_{u,a,m} = \sum_i y_i \cdot w_i / \sum_i w_i$$

donde:

- y_i es la respuesta del encuestado,
- w_i (FACTOR) cuántas personas representa,
- u_i, a_i, m_i es el distrito-año-mes.

Las variables ponderadas que se obtuvieron fueron:

- inseg_total
- inseg_dia



- conf_pnp_baja
- evita_dalir_noche_bin

Unión a DataSet socioeconómico (2022-2024) :

El dataset socioeconómico contiene variables anuales por distrito. por UBIGEO:

- **pob:** Población
- **esp_vida:** Esperanza de vida
- **anios_edu:** Años educación
- **idh:** Índice de Desarrollo
- **per_cap:** Ingreso real per cápita

En el dataset original, las variables se encontraban organizadas en un formato donde la fila superior contenía el año y la inmediatamente inferior contenía las variables anteriormente mencionadas. Este formato no es compatible con herramientas de análisis de datos como Python, ya que genera encabezados multiindex que complican la manipulación de datos.

Se decidió realizar una transformación uniendo ambos niveles, concatenando el nombre del indicador con su respectivo año. Se eliminaron los datos que no corresponden al intervalo de años deseado (2022-2024). Posteriormente se convirtió el dataset a formato plano, de manera que sea consistente con el dataset de encuesta. Finalmente se fusionaron las tablas utilizando merge en UBIGEO06 y ANIO, al no contar con información de manera mensual, se duplicaron los datos de por cada año para todos los meses.

Unión a DataSet denuncias policiales mensuales (SIDPOL) :

El conjunto de datos contiene la siguiente información:

- Ubigeo
- Anio
- Mes
- Modalidad delictiva

Las modalidades se sumaron para obtener una única medida, ya que la investigación no va a contemplar la clasificación de crímenes, sino que observa estos de una manera global. Esto además permite que las entradas sean de la forma **Ubigeo x Mes x Año**, lo cual, es útil para su posterior merge.

Se unieron al panel usando Merge con UBIGEO06, ANIO y MES. Por último se construyó la variable objetivo (tasa de criminalidad), expresada por cada 100 000 habitantes.


Limpieza de datos:

Eliminamos las filas vacías de la variable objetivo "tasa_criminalidad" porque no podíamos tener filas vacías con las que en los test no pudiéramos comparar. También, eliminamos variables que

podrían hacer que nuestro modelo tuviera overfitting como "ANIO" "UBIGEO6" "MES" pero antes de eliminar el mes nos encargamos de usar el seno y coseno para trabajar mejor con esta variable.

//imputación de datos por media o mediana

Con la ayuda del "describe()" y los boxplots pudimos evidenciar que valores numéricos que tenían vacíos deben ser imputados por media o mediana según se necesitara. Además, eliminamos variables que tenían una correlación de más de 0.90.



	anios_edu	idh	per_cap
anios_edu	1.000000	0.936795	0.836557
idh	0.936795	1.000000	0.910212
per_cap	0.836557	0.910212	1.000000

De la matriz de correlación obtenida, notamos que la variable idh presentaba una alta correlación con dos variables, por lo que fue eliminada.

Finalmente, con los histogramas notamos que la variable objetivo tenía un sesgo a la izquierda y con el fin de que el modelo no se enfoque en los valores dentro del sesgo usamos logaritmo para quitar el sesgo o disminuirlo para que no afectará al programa.

División de datos:

Para la configuración experimental y la evaluación de los algoritmos el conjunto de datos (que comprende 36 meses de 2022 a 2024) fue dividido en dos subconjuntos: uno de entrenamiento y otro de prueba.

Debido a la naturaleza predictiva y temporal del problema se aplicó una división cronológica para simular un escenario real de pronóstico. De esta forma el modelo se entrenará exclusivamente con datos del pasado para predecir el futuro, la división la realizamos de la siguiente manera:



- Conjunto de entrenamiento (80%): Se asignaron los primeros 29 meses de datos, abarcando desde enero de 2022 hasta mayo de 2024. Esto para ajustar los parámetros de nuestros modelos.
- Conjunto de pruebas (20%): Se utilizaron los siguientes 7 meses (junio 2024 hasta diciembre 2024). Este subconjunto de datos servirá para evaluar de manera objetiva la capacidad de predicción de nuestro modelo.




Figura 4: Esquema de división cronológica de datos para entrenamiento y prueba.

4. Experimentación y Resultados

Setup experimental:

Para el análisis se modificaron las siguientes variables del dataset:

“Mes”: Se dividió en “mes_cos” y “mes_sin” para tomar en cuenta la estacionalidad

“per_cap”: Se le realizó transformación logarítmica.

“pob”: Se realizó transformación logarítmica debido al posible sesgo observado en su histograma.

“tasa_criminalidad”: Variable objetivo. Debido a su distribución, se le realizó transformación logarítmica, la cual se revertirá al momento de comparar el modelo entrenado, con la data nueva (test_data).

También se realizó estandarización al conjunto de datos de entrenamiento debido a la sensibilidad de KNN y regresión lineal cuando se tiene variable con valores grandes y variables con valores ínfimos a comparación de la primera.

Métricas de evaluación.

Para evaluar el desempeño de los modelos de regresión, se seleccionaron las siguientes métricas:

- Coeficiente de Determinación (R^2): Indica la proporción de la varianza en la tasa de criminalidad que es predecible a partir de las variables independientes. Un valor cercano a 1 indica un ajuste perfecto.
- Error Cuadrático Medio (MSE):

$$MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}$$

Mide la desviación promedio de las predicciones respecto a los valores reales.

Se calcula sobre los valores re-transformados (escala real) para facilitar la interpretación en "número de crímenes por cada 100k habitantes". Para la comparación se usó el negativo del mismo, siendo el más próximo a 0 el mejor candidato.

- Error absoluto medio (MAE):

$$MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$$


Representa el promedio aritmético de los errores absolutos. Es menos sensible a valores extremos que el RMSE

- Desviación estándar:

Usado para analizar la desviación de los puntajes obtenidos en la validación al momento de comparar los modelos.

Selección del modelo base

Para esta parte se usó validación cruzada con 10 folds. Se evaluaron 4 algoritmos, siendo estos regresión lineal, knn con 3 vecinos, knn con 5 vecinos y XGBoost. Para este último se utilizó en primera instancia los parámetros por defecto de la función. Se comparó el nmse (negative mean squared error) para elegir el mejor modelo.




Observamos que el modelo XGBoost fue el que obtuvo mejores resultados, por lo que fue el escogido para continuar con el experimento. Cabe resaltar que al momento de la ejecución los 3 primeros algoritmos fueron casi instantáneos, siendo XGBoost el que demoró más, pero que justifica su mayor precisión.

Análisis del modelo XGBoost


Para determinar la complejidad óptima del modelo XGBoost, se diseñó un experimento iterativo variando el hiperparámetro `n_estimators` en el intervalo [50, 700]. Se mantuvieron constantes los demás hiperparámetros para aislar el efecto de la cantidad de árboles, se fijó un `learning_rate` de 0.1 para garantizar una convergencia estable y una

profundidad máxima de 5 para restringir la complejidad estructural de los árboles y mitigar el riesgo de overfitting temprano. El objetivo fue encontrar donde se maximiza el R^2 .




Del análisis, se obtuvo mejor resultado con $n_{\text{estimators}} = 500$ logrando un R^2 de 0.7189 y un RMSE de 86.81.

Con esta configuración para el modelo, se entrenó y se obtuvieron más métricas como el MAE (54.090979) y la puntuación de varianza explicada (0.726864). Estos valores son aceptables teniendo en cuenta la problemática que se intenta predecir, cuya variable objetivo contiene datos de un rango de 3 a 1700.



Observamos en la gráfica de dispersión, donde se comparan los valores predichos con los valores reales para la data en test, los puntos se ajustan bastante bien a la diagonal, tal y como nos demostró el R^2 obtenido. Sin embargo, esto solo se cumple para tasas menores a 800, ya que para valores mayores notamos una mayor dispersión. Podemos tomar en cuenta que hay muy pocos valores de este tipo en los datos, al ser datos anómalos para la problemática analizada, lo que dificulta la precisión para dichos casos.


En busca de analizar en mayor manera este modelo se realizó la curva de aprendizaje, donde se evalúa su precisión con la data usada de entrenamiento, dependiendo del tamaño del conjunto usado.



Con esta gráfica notamos un claro overfitting. El modelo se ajusta casi perfectamente a los datos usados de entrenamiento, pero se le dificulta con datos nuevos. Si bien hay una mejora considerable (de más de 0.2) desde la mínima cantidad de datos usados, hasta los 4000 totales, la brecha entre ambas curvas sigue siendo notable.

Optimización y Regularización

Para combatir el sobreajuste visto, se modificaron los valores de los hiperparámetros, disminuyendo el ratio de aprendizaje (de 0.1 a 0.02) para que el modelo aprenda más lentamente, el número mínimo necesarios de "hijos" de un nodo (por defecto 1, a 2) y se agregó la regularización llamada alpha (de 0 a 1).



Con tales ajustes, se denota una menor diferencia entre las curvas de entrenamiento y validación, logrando una mayor estabilidad, aunque con esto se causó la disminución del valor R^2 (ahora 0.60835 al comparar datos predichos vs reales).

5. Conclusión

De acuerdo con nuestros objetivos planteados y el análisis experimental realizado sobre la predicción de la tasa de criminalidad en distritos del Perú, se obtuvieron las siguientes conclusiones:



- Se confirmó la superioridad de un modelo basado en gradient boosting (XGBoost), el cual demostró un mejor desempeño durante la cross validación superando a los demás (Regresión lineal y KNN), lo cual indica que la relación entre los factores socioeconómicos, la percepción de inseguridad y la tasa real de criminalidad no es lineal.
- Nuestro modelo final alcanzó un coeficiente R^2 de 0.7193 sobre el conjunto de prueba por lo que si bien existe un margen de error remanente, según el ajuste visual de nuestra gráfica de Predicción vs Real el modelo sigue correctamente la tendencia central, por lo que se considera una herramienta robusta para estimar niveles de riesgo.
- A diferencia de un enfoque completamente reactivo, el enfoque desarrollado nos permite anticipar la tasa de delitos usando variables predictoras disponibles. Aunque el modelo presenta dificultades con valores atípicos extremos, su desempeño general da validez a su uso como herramienta de soporte en la toma de decisiones, para identificar zonas vulnerables en función a su contexto socioeconómico y percepción ciudadana.

6. Sugerencias de trabajos futuros

A partir de nuestros resultados y las limitaciones identificadas durante el desarrollo de este trabajo pudimos determinar las siguientes sugerencias:

- En esta investigación se agruparon todas las modalidades delictivas de un distrito en una única tasa general. Ya que los determinantes de un robo pueden ser distintos a los de una extorsión por ejemplo, se podrían desarrollar modelos especializados para cada tipo de delito principal. Así también se podría ver si ciertas variables socioeconómicas como el grado de educación o el ingreso per cápita tienen algún impacto específico en alguna modalidad en particular.
- Aunque nuestro modelo de XGBoost nos dio un rendimiento superior consideramos que un paso natural sería la implementación de redes neuronales, para así capturar de mejor manera patrones secuenciales complejos en los datos históricos, así como dependencias a largo plazo. Esto en teoría nos daría predicciones más precisas en meses con comportamientos atípicos.

7. Implicancias éticas

A continuación, se describen las principales consideraciones éticas asociadas a una eventual implementación del modelo a escala nacional para la predicción de la criminalidad en el Perú:

Posibles sesgos del modelo:

- **Problema:** El uso de datos socioeconómicos y denuncias policiales podría reflejar desigualdades estructurales y distintos niveles de reporte, generando posibles sesgos en la estimación de criminalidad entre distritos.
- **Solución:** Es recomendable aplicar variación validación estratificada, auditorías de equidad y revisiones periódicas del modelo para mitigar sesgos y asegurar consistencia en las predicciones.

Privacidad de los datos:

- **Problema:** La combinación de múltiples fuentes (denuncias, encuestas y variables socioeconómicas) pueden llevar a una identificación indirecta de distritos como comunidades. Esto podría impactar negativamente su imagen pública y generar efectos sociales no deseados, aún sin identificar individuos.
- **Solución:** Se deben aplicar técnicas de anonimización, agregación adecuada por niveles territoriales y control de acceso. Además, es importante gestionar los resultados con enfoques responsables que eviten etiquetar comunidades, cumpliendo normativas éticas y de protección de datos.

Riesgo de uso indebido:

- **Problema:** Existe el riesgo de que el modelo se utilice para justificar políticas punitivas, vigilancia excesiva o distribución desigual de recursos sin considerar el contexto social.
- **Solución:** El modelo debe emplearse únicamente como sistema de apoyo, bajo principios de gobernanza ética, supervisión humana y acompañamientos de especialistas en seguridad y políticas públicas.

Impacto social:

- **Problema:** La clasificación de distritos según niveles de criminalidad puede fomentar estigmatización territorial y discriminación social.
- **Solución:** Los resultados deben orientarse a la prevención social y al fortalecimiento de servicios públicos, comunicado como estimaciones estadísticas y no como juicios sobre los habitantes.



8. Link del repositorio del trabajo

Entregamos el código en formato ipynb.

9. Declaración de contribución de cada integrante

Saco, S:

E.PARCIAL: Desarrollo de la metodología (Datos y enfoque propuesto), obtención de datasets (ENAPRES).

E.FINAL: Preprocesamiento de datos y unificación de los dataset. Desarrollo de la sección de preprocesamiento. Actualización de las notaciones de cada modelo.

Guevara, C:

E.PARCIAL: Desarrollo de la metodología (Preprocesamiento y elaboración de gráficos y análisis de los datos a usar), obtención de dataset (Censo poblacional).

E.FINAL: Contribución con el desarrollo de la fase de experimentación, elaboración de parte del ppt, de las conclusiones y las sugerencias de trabajos futuros.

Pasache, J:

E. PARCIAL: Desarrollo del resumen e introducción, metodología.

E. FINAL: Preprocesamiento y análisis de datos. Realización de la experimentación y resultados obtenidos.

Reaño C:

E. PARCIAL: Desarrollo de la búsqueda de trabajos relacionados, redacción en formato de cita según guía PUCP.

E. FINAL: Redacción de las implicaciones éticas y contribución en la fase de desarrollo de experimentación.

10. Referencias

- [1]. LI, Victor O. K.
1999 "Hints on writing technical papers and making presentations", IEEE Transactions on Education, vol. 42, no. 2, pp. 134-137
- [2]. WOELFLE, Robert M. (editor)
1992 "New Guide for Better Technical Presentations: Applying Proven Techniques with Modern Tools", IEEE Professional Communication Society. Consulta 8 de octubre de 2025.
www.ieee.org

- [3]. LÓPEZ, Geovanna y MANOSALVAS, Pedro
2023 "Datos y criminalidad: Machine Learning aplicado en modelos predictivos en seguridad". Al Dato. Observatorio Datalat, diciembre de 2023. Quito, Ecuador, pp 1-36. Consulta: 8 de octubre de 2025.
<https://al-dato.datalat.org/wp-content/uploads/2024/01/2.-Geovanna-Lopez-Pedro-Manosalva-Criminalidad-Al-Dato.pdf>
- [4]. GELVEZ-FERREIRA, Juan-David, NIETO-RODRÍGUEZ, María-Paula, y ROCHA-RUIZ, Carlos-Andrés
2022 "Prediciendo el crimen en ciudades intermedias: un modelo de 'machine learning' en Bucaramanga, Colombia". URVIO. Revista Latinoamericana de Estudios de Seguridad, Número 34, septiembre-diciembre 2022. Quito, Ecuador. ISSN impreso: 1390-3691 / ISSN en línea: 1390-4299, pp 1-17. Consulta: 8 de octubre de 2025.
<https://doi.org/10.17141/urvio.34.2022.5395>
- [5]. NQUILLA MAMANI, Juan, LÓPEZ CUEVA, Milton, CATACORA VIDANGOS, Edwin, y FLORES MAMANI, Emilio
2024 "La morfología de la criminalidad urbana en el Perú: un análisis de tendencias, niveles y factores de riesgo". Andamios, Volumen 21, número 55, mayo-agosto 2024. Universidad Autónoma de la Ciudad de México. ISSN impreso: 1870-0063 / ISSN en línea: 2594-1917. Epub: 24 de febrero de 2025. Consulta: 8 de octubre de 2025.
<https://andamios.uacm.edu.mx/index.php/andamios/article/view/1110>
- [6]. ZAMBRANO, Rafael
2020 "Un enfoque espacio-temporal para la predicción de delitos en la ciudad de Buenos Aires". Revista de Investigación en Modelos Matemáticos Aplicados a la Gestión y la Economía, Año 7, Volumen II (2020-II), Universidad de Buenos Aires, Argentina, pp. 1-35. Consulta: 8 de octubre de 2025.
<https://economicas.uba.ar/wp-content/uploads/2016/04/Zambrano-Rafael-1.pdf>

Nota importante:

Figuras y tablas

- Cada figura debe ser leída y comprendida sin necesidad de recurrir a la descripción a lo largo del texto.
- Todos los símbolos usados deben ser explicados en la leyenda.

